

Caracterización espacio-temporal de NO₂ troposférico en la ZMCDMX

Apuntes para Semana 1

Objetivo de la semana. Comprender qué datos se utilizarán en el proyecto, cómo están organizados los archivos satelitales de NO₂ y cómo se transforma una malla diaria de valores espaciales en una serie temporal regional para la Zona Metropolitana de la Ciudad de México. Al terminar esta semana, la participante debe poder verificar la descarga, leer un archivo .he5, identificar la variable de interés y construir una primera serie diaria promedio de NO₂.

Índice

1. Contexto general del servicio social	3
2. Qué es el NO ₂ troposférico	3
3. Fuente de datos: OMI/Aura y producto OMNO2d	4
4. Región de estudio	4
5. Qué significa que los datos estén en una malla	5
6. De la malla diaria a la serie temporal regional	5
7. Estructura de carpetas del proyecto	6
8. Preparación del ambiente de Python	6
9. Verificación de la descarga	6

10.Revisión interna de un archivo satelital	7
11.Construcción de la serie diaria	7
12.Validación básica de la serie temporal	10
13.Serie simplificada para análisis	11
14.Agregación mensual y anual	11
15.Primer gráfica de la serie	12
16.Actividades concretas de la Semana 1	12
17.Entregables de la Semana 1	13
18.Preguntas de repaso	13
19.Ejercicios de trabajo	14
20.Conclusión de la Semana 1	14

1. Contexto general del servicio social

El servicio social se desarrollará en dos periodos de 12 semanas. La meta general es construir, documentar y analizar una serie temporal diaria de dióxido de nitrógeno troposférico, NO₂, para la Zona Metropolitana de la Ciudad de México, usando datos satelitales abiertos de NASA.

Durante el primer periodo se dará prioridad a la parte computacional y metodológica: organización del proyecto, descarga de datos, lectura de archivos satelitales, construcción de bases procesadas y primeras gráficas. Durante el segundo periodo se trabajará con el análisis exploratorio, la interpretación de patrones temporales, la elaboración de figuras finales y la redacción del reporte.

La Semana 1 es fundamental porque establece el objeto principal del proyecto. El producto satelital no entrega directamente una serie de tiempo para la ZMCDMX. En realidad, cada archivo diario contiene una malla de valores de NO₂ sobre una región geográfica. Por eso, el primer paso metodológico consiste en transformar esas mallas diarias en una sola serie temporal regional.

Idea central. En este proyecto no se analiza un sensor puntual ubicado en una estación de monitoreo. Se analiza una serie regional construida a partir de datos satelitales diarios en malla.

2. Qué es el NO₂ troposférico

El dióxido de nitrógeno, NO₂, es un contaminante atmosférico asociado principalmente con procesos de combustión. En una zona metropolitana, fuentes importantes pueden incluir:

- transporte vehicular;
- actividad industrial;
- generación de energía;
- combustión urbana y procesos asociados a la actividad económica.

En este proyecto se estudia el NO₂ troposférico. La troposfera es la capa baja de la atmósfera, donde se desarrolla la mayor parte de los fenómenos meteorológicos y donde se encuentran las emisiones directamente relacionadas con la actividad humana. Por ello, una columna troposférica de NO₂ puede interpretarse como una medida integrada de la cantidad de NO₂ presente en esa parte baja de la atmósfera.

El objetivo del proyecto no es explicar todos los procesos químicos de la atmósfera, sino construir una base de datos ordenada que permita estudiar cómo ha cambiado el NO₂ en la región metropolitana a lo largo del tiempo.

3. Fuente de datos: OMI/Aura y producto OMNO2d

Los datos provienen del producto satelital OMNO2d, asociado al sensor OMI a bordo del satélite Aura. Para este proyecto se utiliza la variable

`ColumnAmountNO2TropCloudScreened.`

Esta variable corresponde a la columna troposférica de NO₂ con un filtrado relacionado con nubosidad. En términos prácticos, es la variable que usaremos como medición satelital diaria de NO₂.

La descarga realizada corresponde al periodo

2005-01-01 a 2024-12-31.

La carpeta de datos crudos es

`data/raw/OMNO2d_ZMCDMX_2005_2024/.`

En esta carpeta se encuentran los archivos originales descargados. Cada archivo representa un día. La descarga produjo 7282 archivos diarios. Este número es ligeramente menor que el número total de días entre 2005 y 2024 porque pueden existir fechas sin archivo disponible o con ausencia de datos útiles.

4. Región de estudio

La región de estudio será la Zona Metropolitana de la Ciudad de México. En esta primera etapa se trabajará con una ventana rectangular amplia que cubre la región metropolitana:

$$-99.80 \leq \lambda \leq -98.50, \quad 18.80 \leq \varphi \leq 20.35,$$

donde λ representa longitud y φ representa latitud.

En código Python, esta región se define como:

```
LON_MIN = -99.80
LAT_MIN = 18.80
LON_MAX = -98.50
LAT_MAX = 20.35
```

Esta ventana rectangular es una primera aproximación. Más adelante se puede mejorar el análisis usando una máscara municipal de la ZMCDMX. Sin embargo, para la Semana 1 el objetivo es construir la primera serie temporal regional con una metodología clara y reproducible.

Convención. En este documento se usará ZMCDMX para referirse a la Zona Metropolitana de la Ciudad de México. La región inicial de trabajo será una caja rectangular que cubre dicha zona.

5. Qué significa que los datos estén en una malla

Los archivos satelitales no contienen un solo valor de NO₂ por día. Cada archivo contiene una matriz de valores distribuidos espacialmente. Conceptualmente, para un día fijo se tiene algo como:

	lon ₁	lon ₂	lon ₃	lon ₄	lon ₅
lat ₁	x_{11}	x_{12}	x_{13}	x_{14}	x_{15}
lat ₂	x_{21}	x_{22}	x_{23}	x_{24}	x_{25}
lat ₃	x_{31}	x_{32}	x_{33}	x_{34}	x_{35}
lat ₄	x_{41}	x_{42}	x_{43}	x_{44}	x_{45}

Cada x_{ij} representa un valor de NO₂ en una celda espacial. Al repetir esto para muchos días, se obtiene una sucesión de mallas:

mallla del día 1, mallla del día 2, ..., mallla del día t .

Para hacer análisis de series de tiempo necesitamos convertir cada malla diaria en un solo valor regional. Ese valor se obtiene promediando las celdas que caen dentro de la región de estudio.

6. De la malla diaria a la serie temporal regional

Sea $X_i(t)$ el valor de NO₂ observado en la celda espacial i durante el día t . Si $\mathcal{R}_t$ es el conjunto de celdas válidas dentro de la región de estudio, el promedio simple diario se define como

$$\bar{X}(t) = \frac{1}{N_t} \sum_{i \in \mathcal{R}_t} X_i(t),$$

donde N_t es el número de celdas válidas en ese día.

Sin embargo, en una malla latitud-longitud, las celdas no tienen exactamente la misma área física sobre la superficie terrestre. La longitud de los paralelos disminuye al alejarse del ecuador. Por esa razón, se usa un promedio ponderado por latitud:

$$\bar{X}_w(t) = \frac{\sum_{i \in \mathcal{R}_t} w_i X_i(t)}{\sum_{i \in \mathcal{R}_t} w_i}, \quad w_i = \cos(\varphi_i),$$

donde φ_i es la latitud de la celda i .

En una región relativamente pequeña como la ZMCDMX, la diferencia entre promedio simple y promedio ponderado no suele ser grande. Aun así, el promedio ponderado es preferible porque respeta mejor la geometría de la malla.

Decisión metodológica. La serie principal del proyecto será la columna `no2_mean_weighted`. La columna `no2_mean` se conservará como comparación.

7. Estructura de carpetas del proyecto

Durante la primera semana se debe organizar el proyecto con una estructura clara. Se recomienda usar:

```
NO2_ZMCDMX/
  data/
    raw/
      OMNO2d_ZMCDMX_2005_2024/
    processed/
  notebooks/
    01_revision_datos_OMNO2d.ipynb
    02_construccion_serie_NO2_ZMCDMX.ipynb
  figures/
  reports/
```

La carpeta `data/raw/` contiene los archivos originales descargados y no debe modificarse manualmente. La carpeta `data/processed/` contiene las bases creadas a partir del procesamiento. La carpeta `notebooks/` contiene el código documentado y la carpeta `figures/` almacena gráficas exportadas.

8. Preparación del ambiente de Python

Para trabajar con los datos se usará Python. Durante la Semana 1 se deben instalar o verificar los siguientes paquetes:

```
pip install numpy pandas matplotlib h5py tqdm earthaccess
```

Los paquetes principales serán:

Paquete	Uso en el proyecto
earthaccess	Búsqueda y descarga de datos NASA.
h5py	Lectura de archivos <code>.he5</code> .
numpy	Cálculo numérico y manejo de matrices.
pandas	Construcción y almacenamiento de bases de datos.
matplotlib	Gráficas de la serie temporal.
tqdm	Barras de progreso durante el procesamiento.

9. Verificación de la descarga

Después de descargar los archivos, el primer paso es comprobar que la carpeta existe y que contiene archivos `.he5`.

```
from pathlib import Path

RAW_DIR = Path("data/raw/OMNO2d_ZMCDMX_2005_2024")
```

```
files = sorted(list(RAW_DIR.glob("*.he5")))  
  
print("Numero de archivos:", len(files))  
print("Primer archivo:", files[0])  
print("Ultimo archivo:", files[-1])
```

La salida esperada debe indicar que existen 7282 archivos. Si el número es muy diferente, se debe revisar la descarga antes de continuar.

Producto de esta sección. Una captura o celda de notebook donde se vea el número total de archivos encontrados, el primer archivo y el último archivo.

10. Revisión interna de un archivo satelital

Antes de procesar todos los archivos, es necesario revisar uno de ellos para saber cómo está organizada su estructura interna. Para eso se usa h5py.

```
import h5py  
  
sample_file = files[0]  
print(sample_file)  
  
with h5py.File(sample_file, "r") as f:  
    def print_structure(name, obj):  
        if isinstance(obj, h5py.Dataset):  
            print(name, obj.shape, obj.dtype)  
  
    f.visititems(print_structure)
```

En la salida se debe identificar una ruta que contenga la variable

ColumnAmountNO2TropCloudScreened.

Esta revisión es importante porque confirma que los archivos descargados contienen la variable que se usará en el análisis.

Producto de esta sección. Una celda donde se muestre la ruta interna de la variable ColumnAmountNO2TropCloudScreened dentro del archivo .he5.

11. Construcción de la serie diaria

La siguiente celda contiene el procedimiento básico para construir la serie temporal diaria. El código lee cada archivo, busca la variable de NO₂, limpia valores faltantes, recorta la región de estudio y calcula dos promedios: simple y ponderado.

```
from pathlib import Path
import re
import h5py
import numpy as np
import pandas as pd
from tqdm import tqdm

RAW_DIR = Path("data/raw/OMNO2d_ZMCDMX_2005_2024")
OUT_DIR = Path("data/processed")
OUT_DIR.mkdir(parents=True, exist_ok=True)

VAR_NAME = "ColumnAmountNO2TropCloudScreened"

LON_MIN = -99.80
LAT_MIN = 18.80
LON_MAX = -98.50
LAT_MAX = 20.35

def infer_date_from_filename(filename):
    match = re.search(r"(\d{4})m(\d{2})(\d{2})", filename)
    if match is None:
        return pd.NaT
    year, month, day = match.groups()
    return pd.Timestamp(f"{year}-{month}-{day}")

def find_dataset(h5obj, target_name):
    matches = []
    def visitor(name, obj):
        if isinstance(obj, h5py.Dataset) and target_name in name:
            matches.append(name)
    h5obj.visititems(visitor)
    if len(matches) == 0:
        return None
    return matches[0]

def clean_array(data):
    data = np.array(data, dtype=float)
    data[data < -1e20] = np.nan
    data[data > 1e30] = np.nan
    return data

def make_lat_lon_grid(data):
    if data.shape == (720, 1440):
        data_std = data
    elif data.shape == (1440, 720):
        data_std = data.T
    else:
        data_std = data

    nlat, nlon = data_std.shape
    lat = np.linspace(-90 + 90/nlat, 90 - 90/nlat, nlat)
    lon = np.linspace(-180 + 180/nlon, 180 - 180/nlon, nlon)
    return data_std, lat, lon
```



```

def weighted_nanmean_by_lat(subset, lat_subset):
    weights_lat = np.cos(np.deg2rad(lat_subset))
    weights = weights_lat[:, None] * np.ones(subset.shape[1])
    mask = np.isfinite(subset)
    if mask.sum() == 0:
        return np.nan
    return np.nansum(subset * weights) / np.nansum(weights * mask)

files = sorted(list(RAW_DIR.glob("*.he5")))
records = []

for file in tqdm(files):
    date = infer_date_from_filename(file.name)

    try:
        with h5py.File(file, "r") as f:
            dataset_path = find_dataset(f, VAR_NAME)

            if dataset_path is None:
                records.append({
                    "date": date,
                    "no2_mean": np.nan,
                    "no2_mean_weighted": np.nan,
                    "no2_median": np.nan,
                    "n_pixels": 0,
                    "status": "variable_not_found",
                    "source_file": file.name
                })
                continue

            data = clean_array(f[dataset_path][...])
            while data.ndim > 2:
                data = data[0]

            data, lat, lon = make_lat_lon_grid(data)

            lat_mask = (lat >= LAT_MIN) & (lat <= LAT_MAX)
            lon_mask = (lon >= LON_MIN) & (lon <= LON_MAX)

            subset = data[np.ix_(lat_mask, lon_mask)]
            lat_subset = lat[lat_mask]

            records.append({
                "date": date,
                "no2_mean": np.nanmean(subset),
                "no2_mean_weighted": weighted_nanmean_by_lat(subset, lat_subset),
                "no2_median": np.nanmedian(subset),
                "n_pixels": int(np.isfinite(subset).sum()),
                "status": "ok",
                "source_file": file.name
            })

    except Exception as e:
        records.append({
            "date": date,

```

```

        "no2_mean": np.nan,
        "no2_mean_weighted": np.nan,
        "no2_median": np.nan,
        "n_pixels": 0,
        "status": f"error: {e}",
        "source_file": file.name
    })

df_daily = pd.DataFrame(records)
df_daily = df_daily.sort_values("date").reset_index(drop=True)

df_daily.to_csv(
    OUT_DIR / "no2_zmcdmx_daily_2005_2024.csv",
    index=False
)

df_daily.head()

```

El archivo principal que debe producirse es

```
data/processed/no2_zmcdmx_daily_2005_2024.csv.
```

12. Validación básica de la serie temporal

Después de construir la serie, se debe revisar que el archivo exista y que las columnas tengan valores razonables.

```

import pandas as pd
from pathlib import Path

serie_file = Path("data/processed/no2_zmcdmx_daily_2005_2024.csv")
print("Existe la serie?", serie_file.exists())

df_daily = pd.read_csv(serie_file)
df_daily["date"] = pd.to_datetime(df_daily["date"])

df_daily.info()
df_daily.head()

```

También se debe revisar el estado del procesamiento:

```
df_daily["status"].value_counts()
```

Y revisar estadísticas descriptivas básicas:

```
df_daily[["no2_mean", "no2_mean_weighted", "no2_median", "n_pixels"]].describe()
```

Criterio de revisión. La columna principal no debe estar formada únicamente por valores faltantes. Además, la columna `n_pixels` debe indicar que se usaron varias celdas válidas por día.

13. Serie simplificada para análisis

Para los análisis posteriores conviene guardar una versión simplificada de la base. Esta versión tendrá solo la fecha, la serie regional ponderada y el número de celdas válidas.

```
serie_no2 = df_daily[["date", "no2_mean_weighted", "n_pixels"]].copy()

serie_no2 = serie_no2.rename(columns={
    "no2_mean_weighted": "no2_zmcdmx"
})

serie_no2.to_csv(
    "data/processed/serie_no2_zmcdmx_diaria_2005_2024.csv",
    index=False
)

serie_no2.head()
```

A partir de este momento, la variable principal del proyecto será `no2_zmcdmx`. Esta variable representa el promedio espacial ponderado diario de NO₂ en la región de estudio.

14. Agregación mensual y anual

Aunque la serie principal es diaria, para visualizar tendencias de largo plazo es útil construir promedios mensuales y anuales.

```
serie_no2["year"] = serie_no2["date"].dt.year
serie_no2["month"] = serie_no2["date"].dt.month

serie_mensual = (
    serie_no2
    .groupby(["year", "month"], as_index=False)
    .agg(
        no2_zmcdmx=("no2_zmcdmx", "mean"),
        dias_validos=("no2_zmcdmx", "count"),
        pixeles_promedio=("n_pixels", "mean")
    )
)

serie_anual = (
    serie_no2
    .groupby("year", as_index=False)
    .agg(
        no2_zmcdmx=("no2_zmcdmx", "mean"),
        dias_validos=("no2_zmcdmx", "count"),
        pixeles_promedio=("n_pixels", "mean")
    )
)

serie_mensual.to_csv(
    "data/processed/serie_no2_zmcdmx_mensual_2005_2024.csv",
    index=False
)
```

```
serie_anual.to_csv(
    "data/processed/serie_no2_zmcdmx_anual_2005_2024.csv",
    index=False
)
```

15. Primera gráfica de la serie

La primera figura del proyecto debe mostrar la serie diaria completa. Esta gráfica sirve para detectar valores faltantes, valores extremos y patrones generales.

```
import matplotlib.pyplot as plt

plt.figure(figsize=(12, 5))
plt.plot(serie_no2["date"], serie_no2["no2_zmcdmx"], linewidth=0.7)
plt.xlabel("Fecha")
plt.ylabel("NO2 troposferico")
plt.title("Serie diaria promedio de NO2 en la ZMCDMX, 2005--2024")
plt.grid(True, alpha=0.3)
plt.tight_layout()
plt.savefig("figures/serie_diaria_no2_zmcdmx_2005_2024.png", dpi=300)
plt.show()
```

También se recomienda graficar la serie mensual:

```
serie_mensual["date"] = pd.to_datetime(
    serie_mensual["year"].astype(str) + "-" +
    serie_mensual["month"].astype(str) + "-01"
)

plt.figure(figsize=(12, 5))
plt.plot(serie_mensual["date"], serie_mensual["no2_zmcdmx"], linewidth=1.2)
plt.xlabel("Fecha")
plt.ylabel("NO2 troposferico")
plt.title("Promedio mensual de NO2 en la ZMCDMX, 2005--2024")
plt.grid(True, alpha=0.3)
plt.tight_layout()
plt.savefig("figures/serie_mensual_no2_zmcdmx_2005_2024.png", dpi=300)
plt.show()
```

16. Actividades concretas de la Semana 1

Durante la Semana 1 se deben completar las siguientes actividades:

1. Crear la estructura de carpetas del proyecto.
2. Verificar que los 7282 archivos .he5 estén en data/raw/OMNO2d_ZMCDMX_2005_2024/.
3. Abrir un archivo con h5py y revisar su estructura interna.
4. Identificar la variable ColumnAmountNO2TropCloudScreened.

5. Explicar por escrito qué significa que los datos estén en una malla espacial.
6. Explicar por escrito por qué se usa un promedio espacial ponderado.
7. Construir el archivo `no2_zmcdmx_daily_2005_2024.csv`.
8. Construir el archivo simplificado `serie_no2_zmcdmx_diaria_2005_2024.csv`.
9. Construir los archivos mensual y anual.
10. Generar al menos dos gráficas: serie diaria y serie mensual.

17. Entregables de la Semana 1

Al final de la Semana 1 se deben entregar los siguientes productos:

Entregable	Descripción
Notebook 1	Archivo <code>01_revision_datos_OMNO2d.ipynb</code> con la verificación de archivos y revisión de un <code>.he5</code> .
Notebook 2	Archivo <code>02_construccion_serie_NO2_ZMCDMX.ipynb</code> con el procesamiento completo.
Base diaria completa	<code>no2_zmcdmx_daily_2005_2024.csv</code> .
Base diaria simplificada	<code>serie_no2_zmcdmx_diaria_2005_2024.csv</code> .
Base mensual	<code>serie_no2_zmcdmx_mensual_2005_2024.csv</code> .
Base anual	<code>serie_no2_zmcdmx_anual_2005_2024.csv</code> .
Figuras preliminares	Gráfica diaria y gráfica mensual en formato <code>.png</code> .
Nota breve	Texto de media a una página explicando qué se hizo y qué representa la serie <code>no2_zmcdmx</code> .

18. Preguntas de repaso

1. ¿Qué contaminante se analiza en este proyecto?
2. ¿Qué significa que el NO₂ sea troposférico?
3. ¿Cuál es la fuente de datos satelitales del proyecto?
4. ¿Cuál es la variable principal dentro de los archivos OMNO2d?
5. ¿Qué significa que cada archivo diario sea una malla espacial?
6. ¿Por qué no tenemos directamente una serie temporal para la ZMCDMX?
7. ¿Qué representa la región rectangular usada en la Semana 1?
8. ¿Cómo se define el promedio espacial simple?
9. ¿Cómo se define el promedio espacial ponderado?

10. ¿Por qué se usa el peso $w_i = \cos(\varphi_i)$?
11. ¿Cuál será la columna principal para el análisis posterior?
12. ¿Qué información contiene la columna `n_pixels`?

19. Ejercicios de trabajo

1. Escribir una explicación de 8 a 10 líneas sobre la diferencia entre una estación de monitoreo y una medición satelital en malla.
2. Abrir uno de los archivos `.he5` y copiar en el notebook la ruta interna de la variable `ColumnAmountNO2TropCloudScreened`.
3. Calcular cuántos archivos se descargaron por año.
4. Verificar si existen fechas faltantes entre 2005-01-01 y 2024-12-31.
5. Construir una tabla con el promedio anual de `no2_zmcdmx`.
6. Identificar visualmente en la gráfica mensual si parece haber estacionalidad.
7. Comparar `no2_mean` y `no2_mean_weighted`. Calcular la diferencia absoluta promedio entre ambas columnas.

Para el ejercicio 7 se puede usar:

```
diff = (df_daily["no2_mean"] - df_daily["no2_mean_weighted"]).abs()
print("Diferencia absoluta promedio:", diff.mean())
```

20. Conclusión de la Semana 1

En esta semana se establece la base técnica del proyecto. La participante debe comprender que los datos satelitales descargados son campos diarios en malla y que la serie temporal regional se obtiene mediante un promedio espacial sobre la región de estudio. La serie principal será el promedio ponderado diario de NO₂ para la ZMCDMX, guardado como `serie_no2_zmcdmx_diaria_2005_2024.csv`.

Con esta base, las siguientes semanas podrán enfocarse en revisar la calidad de la serie, construir resúmenes mensuales y anuales, explorar patrones temporales y preparar visualizaciones más elaboradas.

Bibliografía mínima sugerida

- NASA Goddard Earth Sciences Data and Information Services Center, documentación del producto OMNO2d.
- Seinfeld, J. H. y Pandis, S. N. *Atmospheric Chemistry and Physics*. Wiley.
- Wilks, D. S. *Statistical Methods in the Atmospheric Sciences*. Academic Press.

- McKinney, W. *Python for Data Analysis*. O'Reilly.