

Caracterización espacio-temporal de NO₂ troposférico en la ZMCDMX

Apuntes para Semana 2

El propósito de esta semana es iniciar el análisis exploratorio de la serie diaria de NO₂ troposférico para la Zona Metropolitana de la Ciudad de México. La parte geoespacial avanzada se explica de manera conceptual, pero el trabajo práctico del alumno se realizará con una base de datos final ya procesada.

Índice

1. Propósito de la Semana 2	3
2. Qué se hizo antes de entregar la base final	3
3. Cómo se incorporó la delimitación oficial de la ZMCDMX	3
4. Base de datos final para el alumno	5
5. Sobre la magnitud y unidades de los datos	5
6. Preparación de la base final	6
7. Lectura de la base final	7
8. Primera gráfica: serie diaria	8
9. Promedios mensuales	8
10. Promedios anuales	9
11. Comportamiento estacional	9

12.Revisión básica de calidad	10
13.Mapa de referencia	10
14.Productos concretos de la Semana 2	11
15.Actividades concretas de la Semana 2	11
16.Preguntas de repaso	11
17.Ejercicios de trabajo	11
18.Conclusión de la Semana 2	12

1. Propósito de la Semana 2

Durante la Semana 1 se explicó que los datos satelitales no vienen originalmente como una serie temporal para la ZMCDMX. Cada archivo diario contiene una malla espacial de valores de NO_2 . Para obtener una serie regional es necesario definir una región de estudio y calcular un promedio espacial.

En esta semana se adopta una decisión metodológica importante: la serie principal del proyecto no se calculará usando solamente una caja rectangular, sino tomando en cuenta la delimitación oficial de la Zona Metropolitana de la Ciudad de México. Sin embargo, el alumno no necesita programar todo el procedimiento geoespacial. Para fines del servicio social, se le entregará una base de datos final con la serie diaria ya construida.

2. Qué se hizo antes de entregar la base final

La base final de trabajo se obtiene a partir de tres pasos generales:

1. Se descargaron los archivos diarios del producto satelital OMI/Aura OMNO2d para el periodo 2005–2024.
2. Se usó la delimitación oficial de la ZMCDMX, formada por alcaldías y municipios, para identificar las celdas satelitales que intersectan la región metropolitana.
3. Para cada día se calculó un promedio regional ponderado por la porción de área de cada celda satelital que cae dentro de la ZMCDMX.

La idea matemática se puede resumir así. Si C_i es una celda satelital y $\mathcal{R}$ es la región metropolitana, entonces el peso de la celda i se calcula con base en el área de intersección

$$A_i = \text{area}(C_i \cap \mathcal{R}).$$

Después, la serie regional diaria se define como

$$\overline{\text{NO}_2}(t) = \frac{\sum_i A_i \text{NO}_2(i, t)}{\sum_i A_i}.$$

El alumno no necesita calcular los pesos ni procesar los archivos satelitales originales. Esos pasos forman parte de la preparación de la base. El trabajo de esta semana comienza con el archivo CSV final.

3. Cómo se incorporó la delimitación oficial de la ZMCDMX

Aunque el alumno trabajará directamente con una base final en formato CSV, es importante entender de dónde viene esa base. La diferencia principal respecto a la Semana 1 es que ahora la región de estudio no se define únicamente mediante una caja rectangular de coordenadas. En

su lugar se utiliza una capa geográfica con la delimitación oficial de la Zona Metropolitana de la Ciudad de México.

Esta delimitación está formada por polígonos: cada polígono representa una alcaldía o municipio que forma parte de la región metropolitana. Al unir todos esos polígonos se obtiene una figura irregular, mucho más realista que un rectángulo. Denotaremos esta región por

$$\mathcal{R}.$$

Por otra parte, los datos satelitales de OMI no vienen como puntos aislados, sino como una malla regular de celdas de aproximadamente

$$0.25^\circ \times 0.25^\circ.$$

Cerca de la Ciudad de México, cada celda tiene un tamaño del orden de varias decenas de kilómetros. Por ello, una celda OMI puede quedar completamente dentro de la ZMCDMX, completamente fuera, o solo parcialmente dentro.

El procedimiento seguido para construir la base final fue el siguiente:

1. Se cargó la capa geográfica de la ZMCDMX oficial, construida a partir de alcaldías y municipios.
2. Se construyó la cuadrícula OMI correspondiente a la resolución del producto satelital.
3. Se identificaron las celdas OMI que intersectan la región metropolitana oficial.
4. Para cada celda que intersecta la región, se calculó qué porción de su área cae dentro de la ZMCDMX.
5. Esa área de intersección se usó como peso para calcular el promedio regional diario de NO_2 .

La idea geométrica se resume en la Figura conceptual siguiente: no todas las celdas cuentan igual. Una celda que cae casi completamente dentro de la ZMCDMX debe tener más peso que una celda que apenas toca una pequeña parte de la región.

Si C_i representa la celda OMI número i y $\mathcal{R}$ representa la región metropolitana oficial, entonces se calcula

$$A_i = \text{area}(C_i \cap \mathcal{R}),$$

es decir, el área de la parte de la celda C_i que realmente pertenece a la ZMCDMX. Después, el peso de esa celda se define como

$$w_i = \frac{A_i}{\sum_j A_j}.$$

Con estos pesos, el promedio regional diario se calcula como

$$\overline{\text{NO}_2}(t) = \sum_i w_i \text{NO}_2(i, t),$$

donde $\text{NO}_2(i, t)$ es el valor de NO_2 observado por OMI en la celda i durante el día t .

En palabras simples, la serie final no es un promedio de todas las celdas dentro de un rectángulo. Es un promedio que toma en cuenta la forma oficial de la ZMCDMX y la fracción de cada celda OMI que realmente cae dentro de ella.

Este procedimiento también ayuda a interpretar las columnas de control de la base. La variable `n_cells_valid` indica cuántas celdas OMI tuvieron dato válido en un día dado. La variable `valid_weight_sum` indica qué proporción del peso espacial total estuvo disponible ese día. Si esta cantidad es cercana a 1, significa que casi toda la región tuvo información válida; si es menor, significa que parte de las celdas no aportaron dato válido ese día.

Para el alumno, esta parte debe entenderse como la justificación metodológica de la base. No se espera que programe la intersección geométrica en esta semana. El objetivo práctico será trabajar con la serie final ya construida y comenzar su análisis exploratorio.

4. Base de datos final para el alumno

El archivo principal de trabajo será:

```
base_no2_zmcdmx_diaria_2005_2024.csv
```

Este archivo debe contener, al menos, las siguientes columnas:

Columna	Descripción
<code>date</code>	Fecha de observación.
<code>no2_zmcdmx</code>	Promedio regional diario de NO_2 en la ZMCDMX, en moléculas/ cm^2 .
<code>year</code>	Año.
<code>month</code>	Mes.
<code>dayofyear</code>	Día del año.
<code>n_cells_valid</code>	Número de celdas OMI con dato válido ese día.
<code>valid_weight_sum</code>	Proporción del peso espacial usado ese día.

La columna principal de análisis será `no2_zmcdmx`. En términos del proyecto, esta columna representa el NO_2 troposférico promedio diario sobre la ZMCDMX, usando la delimitación metropolitana oficial. Sus unidades son moléculas/ cm^2 , por lo que es normal que los valores estén escritos en notación científica o sean del orden de 10^{15} .

5. Sobre la magnitud y unidades de los datos

Al revisar la base es normal encontrar valores numéricamente grandes en la columna `no2_zmcdmx`. Esto no significa que la base esté mal. La variable satelital que se usa en este proyecto no representa una concentración local en superficie, como partes por millón o microgramos por metro cúbico.

Representa una *columna troposférica* de NO₂, es decir, una cantidad integrada verticalmente en la atmósfera sobre cada celda satelital.

Por esta razón, la unidad natural del producto es del tipo

$$\text{moléculas/cm}^2.$$

En este tipo de mediciones, valores del orden de 10^{15} o 10^{16} moléculas/cm² son normales. Por ejemplo, un valor como

$$4.5 \times 10^{15}$$

no debe interpretarse como “4.5” en unidades ordinarias, sino como una columna atmosférica equivalente a 4.5×10^{15} moléculas/cm².

En esta etapa del proyecto conservaremos los valores originales de la base, sin reescalarlos. Esto permite mantener la consistencia con el producto satelital y evita modificar las unidades originales. Sin embargo, al hacer gráficas e interpretaciones se debe mencionar explícitamente que la escala del eje vertical corresponde a moléculas/cm² y que la notación científica es esperada.

Los valores grandes en no2_zmcdmx son normales porque se trabaja con columnas troposféricas de NO₂ en unidades de moléculas/cm². No deben interpretarse como concentraciones locales en superficie.

6. Preparación de la base final

Esta celda es para el responsable del proyecto, no necesariamente para el alumno. Su función es tomar la serie procesada con pesos de área y crear una base limpia con nombres simples.

```
import pandas as pd
from pathlib import Path

OUT_DIR = Path("data/processed")
OUT_DIR.mkdir(parents=True, exist_ok=True)

input_file = OUT_DIR / "no2_zmcdmx_daily_area_weighted_2005_2024.csv"
output_file = OUT_DIR / "base_no2_zmcdmx_diaria_2005_2024.csv"

df = pd.read_csv(input_file)
df["date"] = pd.to_datetime(df["date"])

# Renombrar la variable principal para que sea más fácil de usar.
df = df.rename(columns={
    "no2_zmcdmx_area_weighted": "no2_zmcdmx"
})

# Crear variables temporales simples.
df["year"] = df["date"].dt.year
df["month"] = df["date"].dt.month
df["dayofyear"] = df["date"].dt.dayofyear

# Seleccionar columnas útiles para el alumno.
cols = [
```

```

    "date",
    "no2_zmcdmx",
    "year",
    "month",
    "dayofyear",
    "n_cells_valid",
    "valid_weight_sum"
]

# Si alguna columna de control no existe, se omite.
cols = [c for c in cols if c in df.columns]

base = df[cols].copy()
base.to_csv(output_file, index=False)

print("Base final guardada en:", output_file.resolve())
base.head()

```

7. Lectura de la base final

A partir de este punto comienza el trabajo que sí debe realizar el alumno. La base de trabajo se llama `base_no2_zmcdmx_diaria_2005_2024.csv`. Para evitar problemas con rutas, se recomienda colocar este archivo en la misma carpeta donde se ejecutará el cuaderno de Python. Si el archivo se guarda en otra carpeta, entonces se debe indicar la ruta correspondiente dentro de `pd.read_csv`.

```

import pandas as pd
import matplotlib.pyplot as plt
from pathlib import Path

DATA_FILE = "base_no2_zmcdmx_diaria_2005_2024.csv"
FIG_DIR = Path("figures")
FIG_DIR.mkdir(parents=True, exist_ok=True)

df = pd.read_csv(DATA_FILE)
df["date"] = pd.to_datetime(df["date"])

df.head()

```

Se recomienda revisar primero la estructura de la base:

```
df.info()
```

Y luego obtener un resumen numérico:

```
df[["no2_zmcdmx"]].describe()
```

Si la base incluye columnas de control, también puede revisarse cuántas celdas válidas se usaron por día:

```

if "n_cells_valid" in df.columns:
    df["n_cells_valid"].describe()

```

8. Primera gráfica: serie diaria

La primera tarea es visualizar la serie diaria completa.

```
plt.figure(figsize=(13, 5))
plt.plot(df["date"], df["no2_zmcdmx"], linewidth=0.6)

plt.xlabel("Fecha")
plt.ylabel(r"NO$_2$ troposférico (moléculas/cm$^2$)")
plt.title("Serie diaria de NO$_2$ troposférico en la ZMCDMX, 2005--2024")
plt.grid(True, alpha=0.3)
plt.ticklabel_format(style="sci", axis="y", scilimits=(0, 0))
plt.tight_layout()

plt.savefig(FIG_DIR / "serie_diaria_no2_zmcdmx.png", dpi=200)
plt.show()
```

Esta gráfica permite observar la variabilidad diaria. Es normal que la serie tenga mucho ruido, porque las mediciones satelitales diarias pueden cambiar por condiciones meteorológicas, nubosidad, calidad del dato y variación real de emisiones.

9. Promedios mensuales

Para observar mejor la tendencia general, se puede calcular un promedio mensual.

```
monthly = (
    df
    .set_index("date")
    .resample("MS")
    .agg(
        no2_zmcdmx=("no2_zmcdmx", "mean"),
        valid_days=("no2_zmcdmx", "count")
    )
    .reset_index()
)

monthly.head()
```

Después se grafica la serie mensual:

```
plt.figure(figsize=(13, 5))
plt.plot(monthly["date"], monthly["no2_zmcdmx"], linewidth=1.2)

plt.xlabel("Fecha")
plt.ylabel(r"NO$_2$ troposférico (moléculas/cm$^2$)")
plt.title("Promedio mensual de NO$_2$ en la ZMCDMX")
plt.grid(True, alpha=0.3)
plt.ticklabel_format(style="sci", axis="y", scilimits=(0, 0))
plt.tight_layout()

plt.savefig(FIG_DIR / "promedio_mensual_no2_zmcdmx.png", dpi=200)
plt.show()
```


10. Promedios anuales

El promedio anual permite estudiar cambios de largo plazo.

```
annual = (
    df
    .groupby("year", as_index=False)
    .agg(
        no2_zmcdmx=("no2_zmcdmx", "mean"),
        valid_days=("no2_zmcdmx", "count")
    )
)

annual.head()
```

Gráfica anual:

```
plt.figure(figsize=(10, 5))
plt.plot(annual["year"], annual["no2_zmcdmx"], marker="o", linewidth=1.5)

plt.xlabel("Año")
plt.ylabel(r"NO$_2$ troposférico (moléculas/cm$^2$)")
plt.title("Promedio anual de NO$_2$ en la ZMCDMX")
plt.grid(True, alpha=0.3)
plt.ticklabel_format(style="sci", axis="y", scilimits=(0, 0))
plt.tight_layout()

plt.savefig(FIG_DIR / "promedio_anual_no2_zmcdmx.png", dpi=200)
plt.show()
```

11. Comportamiento estacional

También es útil revisar si existen diferencias entre meses. Para ello se calcula el promedio por mes del año usando todos los años disponibles.

```
seasonal = (
    df
    .groupby("month", as_index=False)
    .agg(
        no2_zmcdmx=("no2_zmcdmx", "mean"),
        sd_no2=("no2_zmcdmx", "std"),
        n_days=("no2_zmcdmx", "count")
    )
)

seasonal
```

Gráfica del ciclo estacional:

```
plt.figure(figsize=(10, 5))
plt.plot(seasonal["month"], seasonal["no2_zmcdmx"], marker="o", linewidth=1.5)

plt.xticks(range(1, 13))
```

```
plt.xlabel("Mes")
plt.ylabel(r"NO$_2$ troposférico promedio (moléculas/cm$^2$)")
plt.title("Ciclo estacional promedio de NO$_2$ en la ZMCDMX")
plt.grid(True, alpha=0.3)
plt.ticklabel_format(style="sci", axis="y", scilimits=(0, 0))
plt.tight_layout()

plt.savefig(FIG_DIR / "ciclo_estacional_no2_zmcdmx.png", dpi=200)
plt.show()
```

12. Revisión básica de calidad

Antes de interpretar resultados conviene revisar si hay días faltantes o días con pocos datos válidos.

```
# Días con valor faltante de NO2
missing_no2 = df[df["no2_zmcdmx"].isna()]
print("Días sin NO2:", len(missing_no2))

# Revisar días con baja cobertura espacial, si existe la columna.
if "valid_weight_sum" in df.columns:
    low_coverage = df[df["valid_weight_sum"] < 0.5]
    print("Días con cobertura espacial menor a 50%:", len(low_coverage))
    display(low_coverage.head())
```

Esta revisión no busca resolver todavía todos los problemas de calidad. Su objetivo es que el alumno comience a familiarizarse con la base y entienda que una serie satelital puede tener días con menor disponibilidad de datos.

13. Mapa de referencia

Además de la base CSV, se recomienda entregar al alumno el mapa interactivo:

```
figures/zmcdmx_oficial_y_cuadrícula_omi.html
```

El alumno debe abrirlo en el navegador y observar:

- la delimitación oficial de la ZMCDMX;
- las celdas OMI que intersectan la región;
- el tamaño aproximado de las celdas satelitales;
- por qué el análisis es regional y no de detalle por colonia o municipio.

No se requiere que el alumno reconstruya el mapa durante esta semana. El mapa se usa como apoyo conceptual para interpretar la base de datos.

14. Productos concretos de la Semana 2

Al finalizar esta semana se espera contar con:

1. Base limpia: `base_no2_zmcdmx_diaria_2005_2024.csv`.
2. Gráfica de la serie diaria: `serie_diaria_no2_zmcdmx.png`.
3. Gráfica del promedio mensual: `promedio_mensual_no2_zmcdmx.png`.
4. Gráfica del promedio anual: `promedio_anual_no2_zmcdmx.png`.
5. Gráfica del ciclo estacional: `ciclo_estacional_no2_zmcdmx.png`.
6. Un breve comentario escrito sobre lo observado en las gráficas.

15. Actividades concretas de la Semana 2

Actividad 1. Abrir el mapa interactivo de la ZMCDMX oficial y describir qué representa.

Actividad 2. Cargar la base `base_no2_zmcdmx_diaria_2005_2024.csv` en Python.

Actividad 3. Revisar las columnas, número de registros y rango de fechas.

Actividad 4. Graficar la serie diaria de NO_2 .

Actividad 5. Calcular y graficar el promedio mensual.

Actividad 6. Calcular y graficar el promedio anual.

Actividad 7. Calcular y graficar el ciclo estacional promedio por mes.

Actividad 8. Escribir un resumen de media cuartilla sobre los patrones observados.

16. Preguntas de repaso

1. ¿Por qué la serie final se calcula usando la delimitación oficial de la ZMCDMX y no solo una caja rectangular?
2. ¿Qué representa la columna `no2_zmcdmx`?
3. ¿Por qué la serie diaria se observa más ruidosa que la serie mensual?
4. ¿Qué información aporta el promedio anual?
5. ¿Qué meses parecen tener mayores o menores niveles promedio de NO_2 ?

17. Ejercicios de trabajo

Ejercicio 1. Encontrar la fecha mínima y máxima de la base.

- Ejercicio 2.** Calcular el número de días con dato válido de NO_2 .
- Ejercicio 3.** Identificar el año con mayor promedio anual de NO_2 .
- Ejercicio 4.** Identificar el año con menor promedio anual de NO_2 .
- Ejercicio 5.** Identificar el mes del año con mayor promedio de NO_2 .
- Ejercicio 6.** Repetir la gráfica mensual usando una media móvil de 3 meses.
- Ejercicio 7.** Escribir tres observaciones cualitativas sobre la evolución de la serie.

18. Conclusión de la Semana 2

En esta semana el proyecto pasa de la preparación de datos a la exploración inicial de la serie temporal. La delimitación metropolitana oficial y el promedio ponderado por área se mantienen como base metodológica, pero el alumno trabaja con una base final ya procesada. Esto permite concentrarse en tareas más adecuadas para el avance inicial del servicio social: lectura de datos, descripción de variables, elaboración de gráficas y primeras interpretaciones.

Bibliografía mínima sugerida

- NASA Goddard Earth Sciences Data and Information Services Center, documentación del producto OMNO2d.
- INEGI, Marco Geoestadístico y recursos cartográficos municipales.
- CONAPO, SEDATU e INEGI, delimitación de zonas metropolitanas de México.
- Documentación de `pandas` y `matplotlib`.