

Caracterización espacio-temporal de NO₂ troposférico en la ZMCDMX

Apuntes para Semana 3

El propósito de esta semana es evaluar la integridad y calidad de la serie diaria de NO₂ troposférico construida para la ZMCDMX, calcular estadísticas descriptivas básicas y estudiar si los días con baja cobertura espacial modifican de manera importante los resultados del análisis.

Índice

1. Propósito de la Semana 3	3
2. Base de trabajo y preparación inicial	3
3. Integridad temporal de la base	4
3.1. Fechas inválidas	4
3.2. Fechas duplicadas	4
3.3. Días ausentes	5
3.4. Valores faltantes de NO ₂	5
4. Resumen de integridad temporal	5
5. Cobertura espacial de las observaciones	6
5.1. Revisión de rangos	6
5.2. Histograma de cobertura	7
5.3. Evolución temporal de la cobertura	7
6. Clasificación operativa de calidad	8

7. Cobertura por año	9
8. Estadística descriptiva del NO₂	10
8.1. Resumen general	10
9. Distribución de los valores diarios	11
9.1. Histograma del NO ₂	11
9.2. Diagrama de caja	12
10. Identificación descriptiva de valores extremos	12
11. Comparación por mes del año	13
12. Comparación entre la serie completa y la serie filtrada	14
12.1. Comparación de estadísticas	14
12.2. Comparación del ciclo estacional	15
13. Medias móviles como apoyo visual	17
14. Construcción de la base con indicadores de calidad	18
15. Guía para interpretar los resultados	18
16. Productos concretos de la Semana 3	18
17. Conclusión de la Semana 3	19

1. Propósito de la Semana 3

Durante la Semana 2 se trabajó con la base final `base_no2_zmcdmx_diaria_2005_2024.csv`. Se construyeron las primeras gráficas de la serie diaria, los promedios mensuales y anuales, y el ciclo estacional promedio. También se introdujeron dos variables de control: `n_cells_valid` y `valid_weight_sum`.

En esta semana se estudiarán esas variables con mayor detalle. Antes de interpretar tendencias o anomalías es necesario verificar que la base sea consistente y conocer qué tan completa fue la cobertura espacial de cada día. El análisis tendrá tres componentes:

1. revisión de la integridad temporal de la base;
2. análisis de la cobertura espacial y construcción de indicadores de calidad;
3. estadística descriptiva y comparación entre la serie completa y una serie filtrada.

Una observación satelital con baja cobertura no necesariamente es incorrecta. Sin embargo, debe identificarse para evitar que un día con muy poca información espacial tenga la misma interpretación que un día con cobertura casi completa.

2. Base de trabajo y preparación inicial

Se utilizará nuevamente el archivo:

```
base_no2_zmcdmx_diaria_2005_2024.csv
```

La base debe contener, al menos, las siguientes columnas:

Columna	Descripción
date	Fecha de observación.
no2_zmcdmx	Promedio regional diario de NO ₂ .
year	Año.
month	Mes.
dayofyear	Día del año.
n_cells_valid	Número de celdas OMI con dato válido.
valid_weight_sum	Proporción del peso espacial disponible.

Primero se importan las bibliotecas y se carga la información:

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from pathlib import Path

DATA_FILE = "base_no2_zmcdmx_diaria_2005_2024.csv"
```

```
FIG_DIR = Path("figures_semana_03")
OUT_DIR = Path("data/processed")

FIG_DIR.mkdir(parents=True, exist_ok=True)
OUT_DIR.mkdir(parents=True, exist_ok=True)

df = pd.read_csv(DATA_FILE)
df["date"] = pd.to_datetime(df["date"], errors="coerce")
df = df.sort_values("date").reset_index(drop=True)

df.head()
```

Se recomienda verificar las columnas disponibles:

```
print(df.columns.tolist())
df.info()
```

3. Integridad temporal de la base

Una serie diaria debe revisarse antes de cualquier análisis. Los principales problemas que se buscarán son:

- fechas que no pudieron convertirse correctamente;
- registros duplicados;
- días ausentes dentro del periodo de estudio;
- días presentes pero sin valor de NO₂.

3.1. Fechas inválidas

La opción `errors="coerce"` usada al convertir la fecha reemplaza por NaT cualquier texto que no pueda interpretarse como una fecha válida.

```
invalid_dates = df[df["date"].isna()]

print("Registros con fecha inválida:", len(invalid_dates))
invalid_dates.head()
```

Si aparecen registros en esta tabla, deben revisarse en el archivo original antes de continuar.

3.2. Fechas duplicadas

Para una base diaria regional se espera, en principio, un registro por fecha.

```
duplicated_dates = df[df.duplicated(subset="date", keep=False)]

print("Registros asociados con fechas duplicadas:", len(duplicated_dates))
duplicated_dates.sort_values("date").head(10)
```

No se recomienda eliminar duplicados automáticamente sin revisar su origen. Dos filas con la misma fecha podrían deberse a una repetición accidental, pero también a una etapa previa de procesamiento incompleta.

3.3. Días ausentes

La siguiente celda construye el calendario diario esperado entre la fecha mínima y máxima de la base y lo compara con las fechas observadas.

```
start_date = df["date"].min()
end_date = df["date"].max()

expected_dates = pd.date_range(start=start_date, end=end_date, freq="D")
observed_dates = pd.DatetimeIndex(df["date"].dropna().unique())
missing_dates = expected_dates.difference(observed_dates)

print("Fecha inicial:", start_date)
print("Fecha final:", end_date)
print("Días esperados:", len(expected_dates))
print("Fechas distintas observadas:", len(observed_dates))
print("Días ausentes:", len(missing_dates))

missing_dates[:10]
```

3.4. Valores faltantes de NO₂

Un día puede estar incluido en la base y, aun así, no tener un valor válido de NO₂.

```
missing_no2 = df[df["no2_zmcdmx"].isna()]

print("Días presentes sin valor de NO2:", len(missing_no2))
missing_no2.head()
```

Es importante distinguir entre una fecha ausente y una fecha con valor faltante:

- una **fecha ausente** no aparece como fila en el archivo;
- un **valor faltante** aparece como fila, pero no2_zmcdmx es NaN.

4. Resumen de integridad temporal

Se puede guardar un pequeño resumen para documentar el estado de la base:

```
temporal_summary = pd.DataFrame({
    "indicador": [
        "fecha_inicial",
        "fecha_final",
        "dias_esperados",
        "fechas_observadas",
        "dias_ausentes",
    ]
})
```

```

        "registros_fecha_invalida",
        "registros_fecha_duplicada",
        "dias_sin_no2"
    ],
    "valor": [
        start_date,
        end_date,
        len(expected_dates),
        len(observed_dates),
        len(missing_dates),
        len(invalid_dates),
        len(duplicated_dates),
        len(missing_no2)
    ]
})

temporal_summary

```

```

temporal_summary.to_csv(
    OUT_DIR / "resumen_integridad_temporal.csv",
    index=False
)

```

5. Cobertura espacial de las observaciones

La variable `valid_weight_sum` indica qué proporción del peso espacial total estuvo disponible para calcular el promedio regional de cada día. En una base bien construida, esta variable debe tomar valores entre 0 y 1:

$$0 \leq \text{valid_weight_sum} \leq 1.$$

Un valor cercano a 1 indica que casi toda la región aportó información válida. Un valor pequeño indica que el promedio diario se obtuvo con una fracción limitada de la cobertura espacial.

La variable `n_cells_valid` complementa esta información al indicar cuántas celdas OMI tuvieron dato válido. Ambas variables están relacionadas, pero no son idénticas: las celdas pueden tener pesos espaciales distintos.

5.1. Revisión de rangos

```

coverage_cols = [
    c for c in ["n_cells_valid", "valid_weight_sum"]
    if c in df.columns
]

df[coverage_cols].describe()

```

Se debe verificar que `valid_weight_sum` no tenga valores fuera del intervalo esperado:

```

if "valid_weight_sum" in df.columns:
    invalid_coverage = df[
        (df["valid_weight_sum"] < 0) |
        (df["valid_weight_sum"] > 1)
    ]

    print("Registros con cobertura fuera de [0, 1]:", len(invalid_coverage))
    display(invalid_coverage.head())

```

5.2. Histograma de cobertura

```

if "valid_weight_sum" in df.columns:
    plt.figure(figsize=(9, 5))
    plt.hist(
        df["valid_weight_sum"].dropna(),
        bins=30,
        edgecolor="black",
        alpha=0.8
    )

    plt.xlabel("Proporción del peso espacial válido")
    plt.ylabel("Número de días")
    plt.title("Distribución de la cobertura espacial diaria")
    plt.grid(True, alpha=0.3)
    plt.tight_layout()

    plt.savefig(
        FIG_DIR / "histograma_cobertura_espacial.png",
        dpi=200
    )
    plt.show()

```

5.3. Evolución temporal de la cobertura

```

if "valid_weight_sum" in df.columns:
    plt.figure(figsize=(13, 5))
    plt.plot(
        df["date"],
        df["valid_weight_sum"],
        linewidth=0.6
    )

    plt.axhline(0.80, linestyle="--", linewidth=1,
        label="Referencia: 80%")
    plt.axhline(0.50, linestyle="--", linewidth=1,
        label="Referencia: 50%")

    plt.ylim(0, 1.05)
    plt.xlabel("Fecha")
    plt.ylabel("Proporción del peso espacial válido")
    plt.title("Cobertura espacial diaria en la ZMCDMX")
    plt.grid(True, alpha=0.3)

```

```
plt.legend()
plt.tight_layout()

plt.savefig(
    FIG_DIR / "cobertura_espacial_diaria.png",
    dpi=200
)
plt.show()
```

6. Clasificación operativa de calidad

Para facilitar el análisis, se propone una clasificación práctica basada en `valid_weight_sum`:

Categoría	Condición	Interpretación
Alta	$w \geq 0.80$	Cobertura espacial amplia.
Media	$0.50 \leq w < 0.80$	Cobertura parcial.
Baja	$w < 0.50$	Cobertura espacial limitada.
Sin información	w faltante	No se conoce la cobertura.

Estos umbrales son criterios operativos para organizar el trabajo de esta etapa. No deben presentarse como estándares universales del producto satelital.

```
def classify_quality(weight):
    if pd.isna(weight):
        return "sin_informacion"
    elif weight >= 0.80:
        return "alta"
    elif weight >= 0.50:
        return "media"
    else:
        return "baja"

if "valid_weight_sum" in df.columns:
    df["quality_flag"] = df["valid_weight_sum"].apply(classify_quality)
    df["is_high_quality"] = df["valid_weight_sum"] >= 0.80

    print(df["quality_flag"].value_counts(dropna=False))
```

También es útil calcular porcentajes:

```
if "quality_flag" in df.columns:
    quality_counts = (
        df["quality_flag"]
        .value_counts(dropna=False)
        .rename_axis("quality_flag")
        .reset_index(name="n_days")
    )

    quality_counts["percentage"] = (
        100 * quality_counts["n_days"] / len(df)
```

```
)

quality_counts
```

```
if "quality_flag" in df.columns:
    quality_counts.to_csv(
        OUT_DIR / "resumen_categorias_calidad.csv",
        index=False
    )
```

7. Cobertura por año

La disponibilidad de datos puede cambiar con el tiempo. Por ello, conviene resumir la cobertura para cada año.

```
if "valid_weight_sum" in df.columns:
    coverage_by_year = (
        df
        .groupby("year", as_index=False)
        .agg(
            days_total=("date", "count"),
            days_with_no2=("no2_zmcdmx", "count"),
            mean_coverage=("valid_weight_sum", "mean"),
            median_coverage=("valid_weight_sum", "median"),
            days_high_quality=("is_high_quality", "sum")
        )
    )

    coverage_by_year["pct_high_quality"] = (
        100 * coverage_by_year["days_high_quality"] /
        coverage_by_year["days_total"]
    )

    coverage_by_year
```

```
if "valid_weight_sum" in df.columns:
    coverage_by_year.to_csv(
        OUT_DIR / "resumen_calidad_por_anio.csv",
        index=False
    )
```

Gráfica del porcentaje anual de días con cobertura alta:

```
if "valid_weight_sum" in df.columns:
    plt.figure(figsize=(11, 5))
    plt.bar(
        coverage_by_year["year"],
        coverage_by_year["pct_high_quality"]
    )

    plt.ylim(0, 100)
    plt.xlabel("Año")
    plt.ylabel("Días con cobertura alta (%)")
```

```
plt.title("Disponibilidad anual de observaciones con cobertura alta")
plt.grid(True, axis="y", alpha=0.3)
plt.tight_layout()

plt.savefig(
    FIG_DIR / "porcentaje_calidad_alta_por_anio.png",
    dpi=200
)
plt.show()
```

8. Estadística descriptiva del NO₂

La estadística descriptiva resume la magnitud y variabilidad de la serie sin construir todavía un modelo estadístico. Para una variable $x_1, \dots, x_n$, la media se define como

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i,$$

y la desviación estándar muestral como

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}.$$

También se utilizarán la mediana, los cuartiles y el rango intercuartílico:

$$IQR = Q_3 - Q_1.$$

El coeficiente de variación se define como

$$CV = \frac{s}{\bar{x}},$$

siempre que la media sea distinta de cero. Este indicador expresa la variabilidad relativa respecto a la media.

8.1. Resumen general

```
no2 = df["no2_zmcdmx"].dropna()

q1 = no2.quantile(0.25)
q3 = no2.quantile(0.75)
iqr = q3 - q1
mean_no2 = no2.mean()
std_no2 = no2.std()
cv_no2 = std_no2 / mean_no2 if mean_no2 != 0 else np.nan
```

```
summary_no2 = pd.DataFrame({
    "estadistico": [
        "n",
        "media",
        "mediana",
        "desviacion_estandar",
        "minimo",
        "Q1",
        "Q3",
        "maximo",
        "IQR",
        "coeficiente_variacion"
    ],
    "valor": [
        no2.count(),
        mean_no2,
        no2.median(),
        std_no2,
        no2.min(),
        q1,
        q3,
        no2.max(),
        iqr,
        cv_no2
    ]
})
```

```
summary_no2
```

```
summary_no2.to_csv(
    OUT_DIR / "resumen_estadistico_no2_zmcdmx.csv",
    index=False
)
```

La media y la mediana no responden exactamente a la misma pregunta. La media utiliza todos los valores y puede verse afectada por observaciones extremas. La mediana identifica el punto central de la distribución y suele ser más resistente a valores muy grandes o muy pequeños.

9. Distribución de los valores diarios

9.1. Histograma del NO₂

El histograma permite observar dónde se concentran los valores y si la distribución es aproximadamente simétrica o presenta una cola hacia valores altos.

```
plt.figure(figsize=(9, 5))
plt.hist(
    no2,
    bins=40,
```

```

    edgecolor="black",
    alpha=0.8
)

plt.xlabel(r"NO$_2$ troposférico (moléculas/cm$^2$)")
plt.ylabel("Número de días")
plt.title("Distribución de los valores diarios de NO$_2$")
plt.grid(True, alpha=0.3)
plt.ticklabel_format(style="sci", axis="x", scilimits=(0, 0))
plt.tight_layout()

plt.savefig(FIG_DIR / "histograma_no2_zmcdmx.png", dpi=200)
plt.show()

```

9.2. Diagrama de caja

El diagrama de caja resume la mediana, los cuartiles y posibles valores extremos.

```

plt.figure(figsize=(10, 3.5))
plt.boxplot(no2, vert=False, showfliers=True)

plt.xlabel(r"NO$_2$ troposférico (moléculas/cm$^2$)")
plt.title("Diagrama de caja del NO$_2$ diario")
plt.grid(True, axis="x", alpha=0.3)
plt.ticklabel_format(style="sci", axis="x", scilimits=(0, 0))
plt.tight_layout()

plt.savefig(FIG_DIR / "boxplot_no2_zmcdmx.png", dpi=200)
plt.show()

```

10. Identificación descriptiva de valores extremos

Un criterio exploratorio común considera como valores extremos aquellos que quedan fuera del intervalo

$$[Q_1 - 1.5IQR, Q_3 + 1.5IQR].$$

```

lower_limit = q1 - 1.5 * iqr
upper_limit = q3 + 1.5 * iqr

extreme_values = df[
    (df["no2_zmcdmx"] < lower_limit) |
    (df["no2_zmcdmx"] > upper_limit)
].copy()

print("Límite inferior:", lower_limit)
print("Límite superior:", upper_limit)
print("Número de observaciones extremas:", len(extreme_values))

extreme_values[

```

```
["date", "no2_zmcdmx", "valid_weight_sum"]
].sort_values("no2_zmcdmx", ascending=False).head(10)
```

Un valor extremo no debe eliminarse automáticamente. Puede representar un episodio atmosférico real, un efecto meteorológico, una observación con cobertura limitada o un problema de procesamiento. Primero debe revisarse su fecha, cobertura espacial y contexto temporal.

Para visualizar cuándo ocurrieron esos valores:

```
plt.figure(figsize=(13, 5))
plt.plot(
    df["date"],
    df["no2_zmcdmx"],
    linewidth=0.6,
    label="Serie diaria"
)

plt.scatter(
    extreme_values["date"],
    extreme_values["no2_zmcdmx"],
    s=18,
    label="Valores extremos por criterio IQR"
)

plt.xlabel("Fecha")
plt.ylabel(r"NO$_2$ troposférico (moléculas/cm$^2$)")
plt.title("Localización temporal de valores extremos")
plt.grid(True, alpha=0.3)
plt.legend()
plt.ticklabel_format(style="sci", axis="y", scilimits=(0, 0))
plt.tight_layout()

plt.savefig(FIG_DIR / "valores_extremos_serie_no2.png", dpi=200)
plt.show()
```

11. Comparación por mes del año

El ciclo estacional promedio calculado en la Semana 2 resume cada mes mediante una media. En esta semana se complementará con diagramas de caja, que muestran la distribución completa de los valores diarios de cada mes.

```
month_data = [
    df.loc[df["month"] == month, "no2_zmcdmx"].dropna()
    for month in range(1, 13)
]

plt.figure(figsize=(12, 6))
plt.boxplot(month_data, labels=range(1, 13), showfliers=False)

plt.xlabel("Mes")
plt.ylabel(r"NO$_2$ troposférico (moléculas/cm$^2$)")
```

```
plt.title("Distribución diaria de NO2 por mes del año")
plt.grid(True, axis="y", alpha=0.3)
plt.ticklabel_format(style="sci", axis="y", scilimits=(0, 0))
plt.tight_layout()

plt.savefig(FIG_DIR / "boxplot_no2_por_mes.png", dpi=200)
plt.show()
```

Resumen estadístico por mes:

```
monthly_stats = (
    df
    .groupby("month", as_index=False)
    .agg(
        n_days=("no2_zmcdmx", "count"),
        mean_no2=("no2_zmcdmx", "mean"),
        median_no2=("no2_zmcdmx", "median"),
        std_no2=("no2_zmcdmx", "std")
    )
)

monthly_stats
```

```
monthly_stats.to_csv(
    OUT_DIR / "resumen_no2_por_mes.csv",
    index=False
)
```

12. Comparación entre la serie completa y la serie filtrada

Para evaluar la sensibilidad de los resultados a la cobertura espacial, se construirá una versión filtrada que conserve únicamente días con:

$$\text{valid_weight_sum} \geq 0.80.$$

```
if "valid_weight_sum" in df.columns:
    df_high = df[
        (df["valid_weight_sum"] >= 0.80) &
        (df["no2_zmcdmx"].notna())
    ].copy()

    print("Días en la serie completa:", df["no2_zmcdmx"].count())
    print("Días con cobertura alta:", len(df_high))
    print(
        "Porcentaje conservado:",
        100 * len(df_high) / df["no2_zmcdmx"].count()
    )
```

12.1. Comparación de estadísticas

```

if "valid_weight_sum" in df.columns:
    comparison = pd.DataFrame({
        "serie": ["completa", "cobertura_alta"],
        "n": [
            df["no2_zmcdmx"].count(),
            df_high["no2_zmcdmx"].count()
        ],
        "media": [
            df["no2_zmcdmx"].mean(),
            df_high["no2_zmcdmx"].mean()
        ],
        "mediana": [
            df["no2_zmcdmx"].median(),
            df_high["no2_zmcdmx"].median()
        ],
        "desviacion_estandar": [
            df["no2_zmcdmx"].std(),
            df_high["no2_zmcdmx"].std()
        ]
    })

comparison

```

Se puede calcular la diferencia porcentual entre las medias:

```

if "valid_weight_sum" in df.columns:
    mean_complete = comparison.loc[
        comparison["serie"] == "completa", "media"
    ].iloc[0]

    mean_high = comparison.loc[
        comparison["serie"] == "cobertura_alta", "media"
    ].iloc[0]

    relative_difference = 100 * (
        mean_high - mean_complete
    ) / mean_complete

    print(
        "Diferencia porcentual entre medias:",
        relative_difference
    )

```

```

if "valid_weight_sum" in df.columns:
    comparison.to_csv(
        OUT_DIR / "comparacion_serie_completa_filtrada.csv",
        index=False
    )

```

12.2. Comparación del ciclo estacional

```

if "valid_weight_sum" in df.columns:
    seasonal_complete = (
        df

```

```

        .groupby("month", as_index=False)
        .agg(no2_mean_complete=("no2_zmcdmx", "mean"))
    )

    seasonal_high = (
        df_high
        .groupby("month", as_index=False)
        .agg(no2_mean_high=("no2_zmcdmx", "mean"))
    )

    seasonal_comparison = seasonal_complete.merge(
        seasonal_high,
        on="month",
        how="left"
    )

    seasonal_comparison

```

```

if "valid_weight_sum" in df.columns:
    plt.figure(figsize=(10, 5))

    plt.plot(
        seasonal_comparison["month"],
        seasonal_comparison["no2_mean_complete"],
        marker="o",
        linewidth=1.5,
        label="Serie completa"
    )

    plt.plot(
        seasonal_comparison["month"],
        seasonal_comparison["no2_mean_high"],
        marker="o",
        linewidth=1.5,
        label="Cobertura alta"
    )

    plt.xticks(range(1, 13))
    plt.xlabel("Mes")
    plt.ylabel(r"NO2 promedio (moléculas/cm2)")
    plt.title("Ciclo estacional con y sin filtro de cobertura")
    plt.grid(True, alpha=0.3)
    plt.legend()
    plt.ticklabel_format(style="sci", axis="y", scilimits=(0, 0))
    plt.tight_layout()

    plt.savefig(
        FIG_DIR / "comparacion_ciclo_estacional_calidad.png",
        dpi=200
    )
    plt.show()

```

La comparación debe interpretarse con cuidado. Si las dos curvas son similares, el patrón estacional parece estable frente al filtro de cobertura. Si cambian de manera importante, será necesario revisar en qué meses se concentran los días con cobertura baja.

13. Medias móviles como apoyo visual

La serie diaria tiene variabilidad considerable. Una media móvil ayuda a observar cambios graduales sin reemplazar los datos originales. La media móvil de k días se define como

$$M_t^{(k)} = \frac{1}{k} \sum_{j=0}^{k-1} x_{t-j}.$$

Se calcularán medias móviles de 7 y 30 días:

```
df["no2_ma7"] = df["no2_zmcdmx"].rolling(
    window=7,
    min_periods=4
).mean()

df["no2_ma30"] = df["no2_zmcdmx"].rolling(
    window=30,
    min_periods=15
).mean()

plt.figure(figsize=(13, 5))
plt.plot(
    df["date"],
    df["no2_zmcdmx"],
    linewidth=0.4,
    alpha=0.45,
    label="Serie diaria"
)
plt.plot(
    df["date"],
    df["no2_ma7"],
    linewidth=0.8,
    label="Media móvil de 7 días"
)
plt.plot(
    df["date"],
    df["no2_ma30"],
    linewidth=1.2,
    label="Media móvil de 30 días"
)

plt.xlabel("Fecha")
plt.ylabel(r"NO$_2$ troposférico (moléculas/cm$^2$)")
plt.title("Serie diaria y medias móviles de NO$_2$")
plt.grid(True, alpha=0.3)
plt.legend()
plt.ticklabel_format(style="sci", axis="y", scilimits=(0, 0))
plt.tight_layout()

plt.savefig(FIG_DIR / "serie_no2_medias_moviles.png", dpi=200)
plt.show()
```

La media móvil no debe interpretarse como una nueva medición. Es una transformación de la serie que reduce visualmente la variabilidad de corto plazo.

14. Construcción de la base con indicadores de calidad

Al final de la semana se guardará una nueva versión de la base con las variables creadas durante el análisis:

- `quality_flag`;
- `is_high_quality`;
- `no2_ma7`;
- `no2_ma30`.

```
output_file = (
    OUT_DIR /
    "base_no2_zmcdmx_diaria_calidad_2005_2024.csv"
)

df.to_csv(output_file, index=False)

print("Base con indicadores de calidad guardada en:")
print(output_file.resolve())
```

15. Guía para interpretar los resultados

El comentario escrito de esta semana debe responder, al menos, las siguientes preguntas:

1. ¿La base cubre de manera continua el periodo de estudio?
2. ¿Cuántas fechas están ausentes y cuántos días tienen NO₂ faltante?
3. ¿Qué proporción de los días tiene cobertura espacial alta, media o baja?
4. ¿La cobertura cambia de manera importante entre años?
5. ¿La distribución del NO₂ es aproximadamente simétrica o presenta una cola hacia valores altos?
6. ¿La media y la mediana son similares?
7. ¿En qué meses se observan valores centrales y dispersiones mayores?
8. ¿La media y el ciclo estacional cambian al conservar solamente días con cobertura alta?

No es necesario explicar todavía las causas físicas de todos los patrones. En esta etapa se busca describir correctamente la información disponible y reconocer las limitaciones de la base.

16. Productos concretos de la Semana 3

Al finalizar esta semana se espera contar con:

1. Base con indicadores de calidad: `base_no2_zmcdmx_diaria_calidad_2005_2024.csv`.
2. Resumen de integridad temporal: `resumen_integridad_temporal.csv`.
3. Resumen estadístico general: `resumen_estadistico_no2_zmcdmx.csv`.
4. Resumen de calidad por año: `resumen_calidad_por_anio.csv`.
5. Resumen por mes: `resumen_no2_por_mes.csv`.
6. Histograma del NO₂: `histograma_no2_zmcdmx.png`.
7. Diagrama de caja general: `boxplot_no2_zmcdmx.png`.
8. Diagramas de caja por mes: `boxplot_no2_por_mes.png`.
9. Gráfica de cobertura diaria: `cobertura_espacial_diaria.png`.
10. Comparación estacional con y sin filtro de cobertura: `comparacion_ciclo_estacional_calidad.png`.
11. Gráfica de medias móviles: `serie_no2_medias_moviles.png`.
12. Un comentario escrito de aproximadamente una cuartilla.

17. Conclusión de la Semana 3

En esta semana se realizó una revisión sistemática de la calidad de la serie diaria de NO₂ troposférico para la ZMCDMX. Se distinguieron los problemas de integridad temporal de los problemas de cobertura espacial, se construyeron indicadores operativos de calidad y se calcularon medidas descriptivas de posición y dispersión.

La comparación entre la serie completa y la serie restringida a días con cobertura alta permite evaluar si las conclusiones iniciales dependen de observaciones construidas con información espacial limitada. Esta revisión es necesaria antes de estudiar tendencias de largo plazo, anomalías o cambios asociados con periodos específicos.

La Semana 4 podrá concentrarse en el análisis temporal de mayor detalle: comparación entre años, cuantificación de tendencias y estudio de posibles cambios o periodos anómalos, utilizando la base revisada durante esta semana.

Bibliografía mínima sugerida

- NASA Goddard Earth Sciences Data and Information Services Center, documentación del producto OMNO2d.
- Documentación de pandas: manejo de datos faltantes, agrupamiento y series temporales.
- Documentación de matplotlib: histogramas, diagramas de caja y gráficas temporales.

- Material introductorio de estadística descriptiva: media, mediana, cuartiles, desviación estándar y rango intercuartílico.